



**Mühendislik ve Doğa Bilimleri Fakültesi**  
**Bilgisayar Mühendisliği Bölümü**

**BİL485 Derin Öğrenme**

LSTM Tabanlı Derin Öğrenme Yaklaşımı ile  
USD/TRY Döviz Kuru Tahmini

**Hazırlayanlar:**

22120205036 Yasir BOZYİĞİT

**Öğretim Görevlisi:** Dr. Öğr. Üyesi İshak Dölek

## İçindekiler Tablosu

<b>ŞEKİL LİSTESİ .....</b>	<b>3</b>
<b>1. Proje Konusu .....</b>	<b>4</b>
1.1. Seçilme Gerekçesi.....	4
1.2. Alanın Önemi.....	5
<b>2. Veri Setinin Belirlenmesi .....</b>	<b>5</b>
<b>3. Uygulanacak Yöntem ve Literatür Karşılaştırması .....</b>	<b>5</b>
3.1 Uygulanacak Yöntem .....	6
3.2 Literatür Karşılaştırması .....	6
<b>4. Model Eğitimi .....</b>	<b>7</b>
<b>5. Model Değerlendirilmesi .....</b>	<b>8</b>
<b>6. Sonuç .....</b>	<b>9</b>
<b>7. Kaynakça .....</b>	<b>11</b>
<b>8. Ekler.....</b>	<b>12</b>
Ek A: Proje Kaynak Kodu .....	12
Ek B: Kullanılan Veri Seti .....	12

## ŞEKİL LİSTESİ

Şekil 1 Eğitim sürecinde loss değişimi .....	7
Şekil 2 Gerçek ve tahmin edilen USD/TRY değerleri.....	9

# 1. Proje Konusu

Bu projenin konusu, USD/TRY döviz kurunun geçmiş değerlerinden yararlanarak bir sonraki günün döviz kuru değerinin tahmin edilmesidir. Çalışma kapsamında, finansal zaman serilerinin modellenmesinde sıklıkla kullanılan Uzun Kısa Süreli Bellek (Long Short-Term Memory – LSTM) tabanlı derin öğrenme yaklaşımı kullanılmıştır.

Döviz kurları; ülkelerin ekonomik göstergeleri, enflasyon oranları, faiz politikaları ve küresel gelişmeler gibi birçok faktörden etkilenmektedir. Bu nedenle döviz kuru verileri, karmaşık ve doğrusal olmayan bir yapıya sahiptir. Geleneksel istatistiksel yöntemler bu tür karmaşık örüntüleri modellemede yetersiz kalabilmektedir. Derin öğrenme tabanlı yaklaşımlar ise, zaman serisi verilerindeki kısa ve uzun dönemli bağımlılıkları öğrenebilme yeteneği sayesinde bu alanda daha başarılı sonuçlar sunmaktadır.

Bu projede, 2010–2024 yılları arasındaki günlük USD/TRY döviz kuru verileri kullanılarak bir zaman serisi tahmin modeli geliştirilmiştir. Model, son dört güne ait döviz kuru değerlerini girdi olarak almakta ve bir sonraki günün USD/TRY değerini tahmin etmektedir. Böylece geçmiş fiyat hareketlerinden öğrenilen örüntüler kullanılarak geleceğe yönelik öngörude bulunulması amaçlanmıştır.

Çalışmanın temel hedefi, derin öğrenme yöntemlerinden biri olan LSTM ağlarının finansal zaman serisi tahmin problemlerinde uygulanabilirliğini göstermek ve elde edilen sonuçları değerlendirmektir. Bu kapsamda geliştirilen model, hem akademik açıdan hem de gerçek hayat uygulamaları açısından anlamlı bir örnek sunmaktadır.

## 1.1. Seçilme Gerekçesi

Finansal zaman serilerinin modellenmesi ve geleceğe yönelik tahminlerin yapılması, ekonomi ve finans alanlarında büyük önem taşımaktadır. Döviz kurları; ülkelerin ekonomik durumu, politik gelişmeler ve küresel piyasa hareketlerinden doğrudan etkilenmektedir. Özellikle USD/TRY döviz kuru, Türkiye ekonomisi açısından kritik bir gösterge olup hem bireysel hem de kurumsal karar mekanizmalarında sıklıkla kullanılmaktadır.

Bu projede, USD/TRY döviz kurunun geçmiş değerlerinden yararlanarak bir sonraki günün tahmin edilmesi amaçlanmıştır. Geleneksel istatistiksel yöntemler yerine, zaman serisi verilerinde başarılı sonuçlar verdiği bilinen derin öğrenme tabanlı Uzun Kısa Süreli Bellek (LSTM) ağları tercih edilmiştir. LSTM mimarisi, geçmiş zaman adımlarındaki bağımlılıkları öğrenebilme yeteneği sayesinde finansal zaman serilerinin modellenmesi için uygun bir yapı sunmaktadır.

## 1.2. Alanın Önemi

Finansal zaman serisi tahmini, yatırım stratejilerinin belirlenmesi, risk yönetimi ve ekonomik analizler açısından önemli bir araştırma alanıdır. Doğru tahmin modelleri, belirsizliklerin azaltılmasına ve daha bilinçli kararlar alınmasına katkı sağlar. Son yıllarda derin öğrenme yöntemleri, karmaşık ve doğrusal olmayan veri yapılarında geleneksel yöntemlere kıyasla daha başarılı sonuçlar üretmektedir.

Bu bağlamda, LSTM tabanlı modellerin döviz kuru tahminindeki performansının incelenmesi, hem akademik hem de uygulamalı açıdan değer taşımaktadır. Bu proje, derin öğrenme yöntemlerinin finansal veriler üzerindeki uygulanabilirliğini göstermesi açısından önemlidir.

## 2. Veri Setinin Belirlenmesi

Bu çalışmada kullanılan veri seti, Kaggle platformu üzerinden temin edilen “USD to TL Currency (2010–2024)” veri setidir. Veri seti, 2010 yılından 2024 yılına kadar olan dönemdeki günlük USD/TRY döviz kuru değerlerini içermektedir. Uzun bir zaman aralığını kapsamaması ve gerçek piyasa verilerinden oluşması nedeniyle, söz konusu veri seti finansal zaman serisi tahmini için uygun bir yapı sunmaktadır.

Veri seti iki temel sütundan oluşmaktadır. Bunlar tarih bilgisini içeren date sütunu ve günlük USD/TRY döviz kuru değerlerini içeren currency\_usd\_to\_tl sütunudur. Model eğitimi sürecinde yalnızca döviz kuruna ait sayısal değerler kullanılmış, tarih bilgisi ise zaman sıralamasının korunması ve analiz amacıyla değerlendirilmiştir.

Finansal veriler genellikle farklı ölçeklerde değerler içerebildiğinden, modelin daha sağlıklı ve stabil bir şekilde öğrenebilmesi için veri setine ön işleme adımları uygulanmıştır. Bu kapsamda döviz kuru değerleri, min–max normalizasyon yöntemi kullanılarak  $[0,1]$  aralığına ölçeklendirilmiştir. Normalizasyon işlemi, modelin eğitim sürecinde sayısal kararlılığı artırmış ve öğrenme sürecini olumlu yönde etkilemiştir.

Ayrıca, zaman serisi tahmini problemi doğrultusunda veri seti yeniden düzenlenmiş ve model girdileri, son dört güne ait döviz kuru değerleri olacak şekilde oluşturulmuştur. Bu yapı sayesinde modelin geçmiş zaman adımlarındaki değişimleri öğrenerek bir sonraki günün döviz kuru değerini tahmin etmesi hedeflenmiştir.

## 3. Uygulanacak Yöntem ve Literatür Karşılaştırması

Finansal zaman serilerinin modellenmesi ve tahmin edilmesi, verilerin doğrusal olmayan yapısı ve yüksek oynaklığı nedeniyle zor bir problemdir. Döviz kuru gibi ekonomik

göstergeler, geçmiş değerlere bağımlı olmakla birlikte ani değişimler ve uzun dönemli eğilimler içerebilmektedir. Bu nedenle, kullanılan yöntemin hem kısa hem de uzun vadeli bağımlılıkları öğrenebilme yeteneğine sahip olması büyük önem taşımaktadır.

### 3.1 Uygulanacak Yöntem

Bu projede, zaman serisi tahmini için Uzun Kısa Süreli Bellek (Long Short-Term Memory – LSTM) ağı kullanılmıştır. LSTM, tekrarlayan sinir ağlarının (Recurrent Neural Networks – RNN) geliştirilmiş bir türü olup, klasik RNN’lerde karşılaşılan uzun vadeli bağımlılıkların öğrenilememesi problemini çözmek amacıyla geliştirilmiştir.

LSTM mimarisi; hücre durumu (cell state) ve giriş, çıkış ile unutma kapılarından (input, output, forget gates) oluşan yapısı sayesinde geçmiş bilgileri uzun süre saklayabilmekte ve gerekli durumlarda bu bilgileri kullanabilmektedir. Bu özellik, özellikle döviz kuru gibi geçmiş fiyat hareketlerinden güçlü şekilde etkilenen zaman serileri için LSTM modellerini uygun hale getirmektedir.

Bu çalışmada geliştirilen LSTM modeli, son dört güne ait USD/TRY döviz kuru değerlerini girdi olarak almakta ve bir sonraki günün döviz kuru değerini tahmin etmektedir. Böylece modelin, geçmiş fiyat hareketlerindeki örüntüleri öğrenerek geleceğe yönelik tahmin yapması amaçlanmıştır.

### 3.2 Literatür Karşılaştırması

Finansal zaman serisi tahmininde literatürde farklı yöntemler yaygın olarak kullanılmaktadır. Bu yöntemler genel olarak istatistiksel yaklaşımlar ve makine öğrenmesi / derin öğrenme tabanlı yaklaşımlar olarak iki gruba ayrılabilir.

Geleneksel istatistiksel yöntemlerden biri olan ARIMA (AutoRegressive Integrated Moving Average) modeli, zaman serilerinin doğrusal ilişkilerini modelleyebilmekte ve kısa vadeli tahminlerde kullanılabilmektedir. Ancak ARIMA gibi yöntemler, doğrusal varsayımlar üzerine kurulu olmaları nedeniyle finansal verilerdeki karmaşık ve doğrusal olmayan yapıları modellemede yetersiz kalabilmektedir.

Makine öğrenmesi tabanlı yöntemler arasında Destek Vektör Makineleri (SVM) ve yapay sinir ağları yer almaktadır. Bu yöntemler, doğrusal olmayan ilişkileri öğrenebilme kapasitesine sahip olmakla birlikte, zaman serilerindeki uzun dönemli bağımlılıkları yakalamada sınırlı performans gösterebilmektedir.

Derin öğrenme yaklaşımlarından RNN (Recurrent Neural Network) modelleri, zaman bağımlı veriler için geliştirilmiş olsa da, uzun dizilerde gradyan kaybolması problemi nedeniyle geçmiş bilgiyi yeterince koruyamamaktadır. Bu sorunu aşmak amacıyla geliştirilen LSTM modelleri, literatürde finansal zaman serisi tahmininde sıklıkla tercih edilmektedir.

Yapılan birçok çalışmada, LSTM tabanlı modellerin döviz kuru, hisse senedi fiyatları ve enerji tüketimi gibi zaman serilerinde, geleneksel istatistiksel yöntemlere ve klasik RNN modellerine kıyasla daha başarılı sonuçlar ürettiği gösterilmiştir. Bu nedenle, proje kapsamında zaman serisi tahmini problemi için LSTM yaklaşımı tercih edilmiştir.

## 4. Model Eğitimi

Bu projede geliştirilen LSTM tabanlı derin öğrenme modelinin eğitimi, PyTorch kütüphanesi kullanılarak gerçekleştirilmiştir. Model eğitimi sürecinde, zaman serisi verilerinin yapısı dikkate alınarak uygun mimari ve hiperparametreler belirlenmiştir.

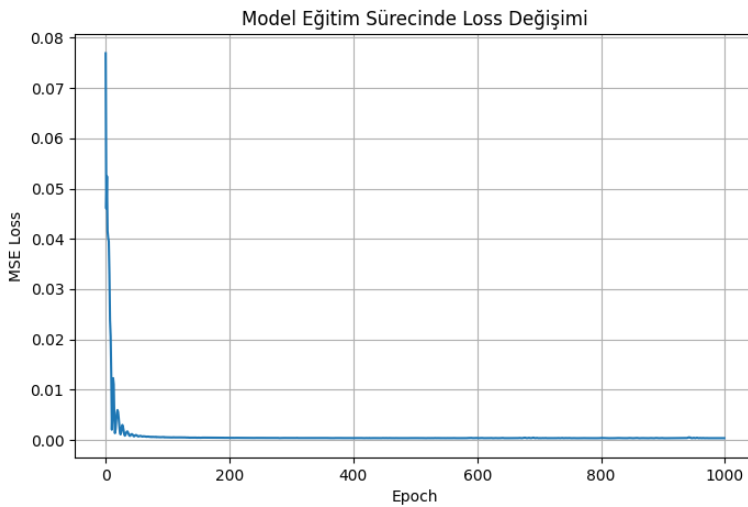
Eğitim öncesinde veri seti, son dört güne ait USD/TRY döviz kuru değerleri girdi olacak şekilde yeniden düzenlenmiştir. Her bir eğitim örneği, dört ardışık günün döviz kuru değerlerinden oluşmakta ve modelin çıktısı bir sonraki günün döviz kuru değerini temsil etmektedir. Bu yapı sayesinde modelin, geçmiş fiyat hareketlerinden geleceğe yönelik tahmin yapabilmesi amaçlanmıştır.

Model mimarisi, tek katmanlı bir LSTM katmanı ve bu katmanın çıktısını tahmin edilen döviz kuru değerine dönüştüren tam bağlantılı bir katmandan oluşmaktadır. Model tasarımında, finansal zaman serilerinin karmaşık yapısını öğrenebilecek yeterli temsil gücü sağlanırken, aşırı karmaşıklıktan kaçınılmıştır.

Eğitim sürecinde kayıp fonksiyonu olarak Ortalama Kare Hatası (Mean Squared Error – MSE) tercih edilmiştir. MSE, regresyon problemlerinde yaygın olarak kullanılan ve tahmin edilen değerler ile gerçek değerler arasındaki farkın karesini ölçen bir metriktir. Optimizasyon algoritması olarak ise adaptif öğrenme oranı sayesinde hızlı ve kararlı yakınsama sağlayan Adam algoritması kullanılmıştır.

Model, 1000 epoch boyunca eğitilmiştir. Eğitim sırasında her epoch sonunda kayıp değeri hesaplanmış ve model parametreleri geriye yayılım (backpropagation) yöntemi ile güncellenmiştir. Eğitim süreci boyunca kayıp değerlerinin istikrarlı bir şekilde azaldığı gözlemlenmiş, bu durum modelin zaman serisi üzerindeki örüntüleri başarıyla öğrendiğini göstermiştir.

Eğitim tamamlandıktan sonra, öğrenilen model parametreleri dosyaya kaydedilmiş ve modelin eğitim sonrası tahmin aşamasında kullanılabilmesi sağlanmıştır.



Şekil 1 Eğitim sürecinde loss değişimi

Şekil 1’de modelin eğitim sürecinde kullanılan MSE kayıp değerinin epoch’lara göre değişimi gösterilmektedir. Eğitim sürecinin başlangıcında yüksek olan kayıp değeri, epoch sayısı arttıkça hızla azalmış ve ilerleyen aşamalarda kararlı bir seviyeye ulaşmıştır. Bu durum, modelin USD/TRY zaman serisi üzerindeki örüntüleri başarılı bir şekilde öğrendiğini göstermektedir.

## 5. Model Değerlendirilmesi

Bu çalışmada geliştirilen LSTM tabanlı modelin performansı, eğitim sürecindeki kayıp (loss) değerleri ve örnek tahmin çıktıları üzerinden değerlendirilmiştir. Model değerlendirme aşamasında, zaman serisi tahmin problemlerinin doğası gereği klasik sınıflandırma metrikleri yerine **regresyon odaklı ölçütler** dikkate alınmıştır.


Model eğitimi sırasında kullanılan **Ortalama Kare Hatası (Mean Squared Error – MSE)** değeri, her epoch sonunda hesaplanmış ve eğitim süreci boyunca düzenli olarak azaldığı gözlemlenmiştir. Kayıp değerindeki bu düşüş, modelin geçmiş USD/TRY döviz kuru verilerindeki örüntüleri öğrenerek tahmin hatasını azalttığını göstermektedir. Eğitim sürecinin kararlı bir şekilde ilerlemesi, seçilen mimari ve hiperparametrelerin uygunluğunu ortaya koymaktadır.

Eğitim tamamlandıktan sonra model, daha önce görmediği son dört güne ait USD/TRY döviz kuru değerlerini girdi olarak almış ve bir sonraki günün döviz kuru tahminini üretmiştir. Elde edilen tahmin sonuçları, modelin geçmiş fiyat hareketlerine dayalı olarak anlamlı ve tutarlı değerler üretebildiğini göstermektedir. Tahmin edilen değerlerin, önceki günlerin birebir devamı olmaması, modelin deterministik bir kural yerine öğrenilmiş örüntülere dayalı tahmin yaptığını ortaya koymaktadır.

Ayrıca, geliştirilen model `serve.py` dosyası kullanılarak servis edilmiş ve Gradio tabanlı bir kullanıcı arayüzü üzerinden test edilmiştir. Bu arayüz sayesinde kullanıcıdan alınan son dört güne ait döviz kuru değerleri modele verilmiş ve modelin tahmin çıktıları gerçek zamanlı olarak gözlemlenmiştir. Bu durum, modelin eğitim sonrası kullanım senaryosunun başarılı bir şekilde gerçekleştirildiğini göstermektedir.

Genel değerlendirme sonucunda, geliştirilen LSTM modelinin finansal zaman serisi tahmin problemlerinde kullanılabilir olduğu ve USD/TRY döviz kuru verileri üzerinde anlamlı tahminler üretebildiği sonucuna varılmıştır.





Şekil 2 Gerçek ve tahmin edilen USD/TRY değerleri

Şekil 2’de model tarafından tahmin edilen USD/TRY döviz kuru değerleri ile gerçek değerler karşılaştırılmıştır. Grafikten görüldüğü üzere model, döviz kurundaki genel trendi takip edebilmekte ve tahmin edilen değerler gerçek değerlere yakın seyretmektedir. Bu sonuç, geliştirilen LSTM modelinin finansal zaman serisi tahmininde kullanılabilir olduğunu göstermektedir.

## 6. Sonuç

Bu çalışmada, USD/TRY döviz kurunun geçmiş değerlerinden yararlanarak bir sonraki günün döviz kuru değerinin tahmin edilmesi amacıyla LSTM tabanlı bir derin öğrenme modeli geliştirilmiştir. Çalışma kapsamında, 2010–2024 yılları arasındaki günlük USD/TRY döviz kuru verileri kullanılmış ve finansal zaman serilerinin modellenmesi problemi ele alınmıştır.

Geliştirilen model, son dört güne ait döviz kuru değerlerini girdi olarak alarak bir sonraki günün tahminini üretmektedir. Eğitim süreci boyunca kayıp değerlerinin istikrarlı bir şekilde azalması, modelin zaman serisi üzerindeki örüntüleri başarılı bir şekilde öğrendiğini göstermiştir. Eğitim sonrası yapılan örnek tahminler ve kullanıcı arayüzü üzerinden gerçekleştirilen testler, modelin geçmiş fiyat hareketlerine dayalı olarak anlamlı tahminler üretebildiğini ortaya koymuştur.

Bu çalışmada elde edilen sonuçlar, LSTM tabanlı derin öğrenme modellerinin finansal zaman serisi tahmin problemlerinde uygulanabilir ve etkili bir yaklaşım sunduğunu göstermektedir. Özellikle uzun dönemli bağımlılıkların öğrenilmesi gereken döviz kuru gibi karmaşık veri yapılarında, LSTM mimarisinin geleneksel yöntemlere kıyasla önemli avantajlar sağladığı görülmüştür.

Gelecek çalışmalarda, model performansının artırılması amacıyla farklı zaman adımı uzunluklarının denenmesi, ek finansal göstergelerin modele dahil edilmesi ve LSTM ile GRU

gibi farklı derin öğrenme mimarilerinin karşılaştırılması planlanabilir. Ayrıca, daha kapsamlı değerlendirme metrikleri kullanılarak model başarımının detaylı biçimde analiz edilmesi mümkündür.

Sonuç olarak, bu proje kapsamında geliştirilen LSTM tabanlı model, finansal zaman serisi tahmini alanında derin öğrenme yaklaşımlarının potansiyelini ortaya koyan başarılı bir uygulama örneği sunmaktadır.

## 7. Kaynakça

1. Hochreiter, S., & Schmidhuber, J. (1997).  
*Long short-term memory*. Neural Computation, 9(8), 1735–1780.  
<https://doi.org/10.1162/neco.1997.9.8.1735>
2. Brownlee, J. (2018).  
*Deep Learning for Time Series Forecasting*. Machine Learning Mastery.
3. Goodfellow, I., Bengio, Y., & Courville, A. (2016).  
*Deep Learning*. MIT Press.
4. Karim, F., Majumdar, S., Darabi, H., & Chen, S. (2019).  
*LSTM fully convolutional networks for time series classification*.  
IEEE Access, 6, 1662–1669.
5. Zhang, G. P. (2003).  
*Time series forecasting using a hybrid ARIMA and neural network model*.  
Neurocomputing, 50, 159–175.
6. Kaggle. (2024).  
*USD to TL Currency (2010–2024)*.  
<https://www.kaggle.com/datasets/gkhanergen/usd-to-try-2010-2024-currency>
7. Paszke, A., Gross, S., Massa, F., et al. (2019).  
*PyTorch: An imperative style, high-performance deep learning library*.  
Advances in Neural Information Processing Systems (NeurIPS).
8. Hyndman, R. J., & Athanasopoulos, G. (2018).  
*Forecasting: Principles and Practice*. OTexts.

## 8. Ekler

### Ek A: Proje Kaynak Kodu

Bu projede geliştirilen derin öğrenme modeli, eğitim ve servis süreçlerine ait tüm kaynak kodlar ile birlikte GitHub platformu üzerinden paylaşılmıştır. Depoda; model mimarisi (model.py), model eğitimi (train.py), modelin servis edilmesi (serve.py) ve projede kullanılan veri setine ilişkin açıklamalar yer almaktadır. Ayrıca, projenin çalıştırılmasına dair gerekli bilgiler GitHub deposunda sunulmuştur.

**GitHub bağlantısı:**

<https://github.com/Yasirbzygt/usdtry-lstm-forecasting>

### Ek B: Kullanılan Veri Seti

Bu çalışmada kullanılan USD/TRY döviz kuru verileri, Kaggle platformu üzerinden temin edilmiştir. Veri seti, 2010–2024 yılları arasındaki günlük USD/TRY değerlerini içermekte olup, finansal zaman serisi tahmini için uygun bir yapı sunmaktadır.

**Veri seti kaynağı:**

Kaggle. (2024). *USD to TL Currency (2010–2024)*.

<https://www.kaggle.com/datasets/gkhanergen/usd-to-try-2010-2024-currency>